

TP02 – Data Scoring
Data Quality – QUALLI-SCORE
24/09/2026

Détection des anomalies dans les données

Groupe de TP

Yahia Khroufi	<i>CNE : S135237967</i>
Abdelhamid Nfissi	<i>CNE : S138200759</i>
Yassine Kerbal	<i>CNE : S139228146</i>

Enseignant : M. Faouzi Boufarès

Année universitaire : 2026–2027

Table des matières

Rappel du travail précédent	2
4 Détection des anomalies dans CLIENTS	2
4.1 Positionner dans le SGB	2
4.2 Import des données avec Pandas	2
4.3 Premier diagnostic des données	3
4.4 Création de la table de visualisation	3
4.5 Détection des anomalies inférieures	4
4.6 Détection des doublons	4
4.7 Détection des anomalies intérieures	5
4.8 Traitement des valeurs manquantes	5
5 Visualisation, diagnostic et scoring	6
5.1 Visualisation des anomalies	6
5.2 Traitement des valeurs manquantes	6
5.3 Correction des valeurs aberrantes	7
5.4 Détecteurs fonctionnels	7
5.5 Résultat après nettoyage	8
5.6 Calcul du score QUALLI-SCORE	8
6 Résultats obtenus	10
6.1 Checklist Data Base	10
7 Limites et observations	11
8 Conclusion	11

Rappel du travail précédent

La base de données utilisée dans ce TP a déjà été créée et alimentée dans le TP1. Les scripts de métadonnées, de fonctions/procédures et de création/insertion des données ont donc déjà été exécutés.

Le présent rapport commence directement par les traitements réalisés avec les scripts suivants. L'objectif est d'interroger et profiler les données, d'identifier les anomalies, de les visualiser, de calculer les indicateurs de qualité (dont le score **QUALLI-SCORE**), puis d'appliquer des opérations de nettoyage et de standardisation.

4 Détection des anomalies dans CLIENTS

4.1 Positionner dans le SGB

Le script MFB04 permet d'interroger les données avec des requêtes SQL avancées et d'effectuer plusieurs contrôles de qualité. Il permet notamment d'identifier des problèmes de format, de casse, d'espaces superflus, de courriels ou de téléphones incorrects, ainsi que certaines incohérences liées aux règles métier.



All rows fetched: 10 in 0.094 seconds

	CODCLI	NOMCLI	PRENCLI
1	C001	CLEMENT	EVE
2	C002	LESEUL	MARIE
3	C005	FORT	anne marie
4	C011	PREMIER	JOS//EPH
5	C120	1	MARIE
6	C121	2 PAR 2	Girard
7	C126	DE PAR DE	Girard
8	C298	TROMPE.	Ronald
9	C299	BIDON!	Joie
10	C300	HOBAAAAA	M'Barek

Figure 1 – Détection de premières anomalies avec les requêtes SQL avancées de MFB04

4.2 Import des données avec Pandas

Le script MFB05 présente le mécanisme d'import de données externes vers Oracle avec SQL*Loader. Le chargement repose sur une table réceptrice, un fichier de contrôle et un fichier de données utilisant le séparateur défini.

```

SQL*Loader: Release 23.26.3.0.0 - Production on Thu Sep 24 17:19:48 2026
Version 23.26.3.0.0

Copyright (c) 1982, 2026, Oracle and/or its affiliates. All rights reserved.

^[[14;1RPath used:      Conventional
Commit point reached - logical record count 5

Table SQLLOADEREXEMPLE:
  5 Rows successfully loaded.

Check the log file:
  /tmp/Controler.log

```

Figure 2 – Chargement de données externes dans Oracle avec SQL*Loader

4.3 Premier diagnostic des données

MFB05 introduit également un premier mécanisme de diagnostic. Une copie de la table CLIENTS est utilisée et enrichie avec des colonnes permettant de compter les valeurs valides, invalides et manquantes.

Les indicateurs utilisés sont :

- T : valeur valide ;
- F : valeur invalide ;
- N : valeur manquante.

All rows fetched: 45 in 0.046 seconds

	ROWNUM	CODCLI	ANOMALIES	VALIDCOL	INVALIDCOL	NULLCOL
1	1	C001	(null)	(null)	(null)	(null)
2	2	C002	(null)	(null)	(null)	(null)
3	3	C003	(null)	(null)	(null)	(null)
4	4	C004	(null)	(null)	(null)	(null)
5	5	C005	(null)	(null)	(null)	(null)
6	6	C006	(null)	(null)	(null)	(null)
7	7	C007	(null)	(null)	(null)	(null)
8	8	C008	(null)	(null)	(null)	(null)
9	9	C009	(null)	(null)	(null)	(null)
10	10	C010	(null)	(null)	(null)	(null)
11	11	C011	(null)	(null)	(null)	(null)
12	12	C012	(null)	(null)	(null)	(null)
13	13	C013	(null)	(null)	(null)	(null)
14	14	C014	(null)	(null)	(null)	(null)
15	15	C015	(null)	(null)	(null)	(null)
16	16	C016	(null)	(null)	(null)	(null)
17	17	C017	(null)	(null)	(null)	(null)
18	18	C018	(null)	(null)	(null)	(null)
19	19	C019	(null)	(null)	(null)	(null)

Figure 3 – Diagnostic de la table COPIE_CLIENTS avec les indicateurs de qualité

4.4 Création de la table de visualisation

Le script MFB06 crée une copie de travail de la table CLIENTS nommée VISU_ANOMALIES_CLIENTS. Cette table permet de détecter et de marquer les anomalies sans modifier directement la source originale.

All rows hidden: 45 in 3.115 seconds

	COL1_CODEL1	COL2_CODEL2	COL3_CODEL3	COL4_CODEL4	COL5_CODEL5	COL6_CODEL6	COL7_CODEL7	COL8_CODEL8	COL9_CODEL9	COL10_CODEL10	COL11_CODEL11	COL12_CODEL12
1	C001	NOMINUM	BEDON	2000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)
2	C001	NOMINUM	CLIMBERT	100	1	10	BOULVARD FOCH	93000	SPYHO-SUR-SEINE	FRANCE	mon.clemon@gmail.com	+3377788999
3	C002	NOMINUM	LEDEUL	NP002	1	17	AVENUE D'ITALIE	75003	PARIS	FRANCE	marielesau@yahoo.fr	+33661750065
4	C003	NOMINUM	UNIQUE	2000	1	77	RUE DE LA LIBERTÉ	10001	MARCELLE	FRANCE	marielesau@gmail.com	+3377788999
5	C004	NOMINUM	CLIMBERT	100	1	10	AVENUE FOCH	93000	SPYHO-SUR-SEINE	FRANCE	climbert.evelyn@gmail.com	+3377788999
6	C005	NOMINUM	PORT	2000	NP001	10	RUE DU JAPON	94100	ORLY-VILLE	FRANCE	2000@gmail.fr	+3377788999
7	C006	NOMINUM	LE BON	CLIMBERT	1	10	BOULVARD FOCH	93000	SPYHO-SUR-SEINE	FRANCE	climbert.lebon@gmail.fr	+3377788999
8	C007	NOMINUM	TRADON	100	1	10	RUE DE LA PAIX	75001	PARIS	FRANCE	elicia.tradon@gmail.fr	+3377788999
9	C008	NOMINUM	VEVANT	JEAN-BAPTISTE	1	17	RUE DE LA PAIX	75000	SPYHO-SUR-SEINE	FRANCE	jeanbaptiste@gmail	0007
10	C009	NOMINUM	CLIMBERT	ADAM	1	1	RUE DE BELLEVILLE	75003	PARIS	(null)	adam.clemon@gmail.fr	+33661750065
11	C010	NOMINUM	TRADON	ADAM	1	17	AVENUE FOCH	75003	PARIS	FRANCE	adam.tradon@gmail.fr	00070000
12	C011	NOMINUM	PRENOM	200/000	2	77/77	RUE DE LA LIBERTÉ	10001	MARCELLE	FRANCE	jeanbaptiste@gmail	+3377788999
13	C012	NOMINUM	CLIMBERT	ADAM	1	10	AVENUE JEAN-BAPTISTE CLEMENT	93000	VELLEMAISON	FRANCE	adam.clemon@gmail.com	+33661750065
14	C013	NOMINUM	PORT	GABRIEL	1	1	AVENUE DE CORTYGE	93000	PARIS	TANGLIS	gabriel.fort@yahoo.fr	+33661750065
15	C014	NOMINUM	ADAM	ADAM	1	1	AVENUE DE ROME	93001	ROME	ITALIE	adam.adam@gmail.com	(null)
16	C015	NOMINUM	ADAM	ADAM	1	1	RUE DES ANTOINES	000	PARIS	FRANCE	adam.adam@gmail.com	(null)
17	C016	NOMINUM	ADAM	ADAM	1	1	RUE DES ANTOINES	000	CARTHAGE	TUNISIE	(null)	(null)
18	C017	NOMINUM	ADAM	ADAM	1	1	RUE DES ANTOINES	1000	CARTHAGE	TUNISIE	karyn.ray@gmail.com	+33661750065
19	C018	NOMINUM	ADAM	ADAM	1	1	BOULVARD FOCH	93000	SPYHO-SUR-SEINE	FRANCE	adam.glemon@gmail.com	+3377788999
20	C019	NOMINUM	GENIE	GENIE	1	10	AVENUE FOCH	75003	PARIS	FRANCE	genielesau@gmail.com	+3377788999
21	C020	NOMINUM	GENIE	GENIE	1	10	AVENUE FOCH	75003	PARIS	FRANCE	genielesau@gmail.com	+33661750065
22	C021	NOMINUM	LAURENCE	LAURENCE	1	10	AVENUE FOCH	75003	PARIS	FRANCE	laurence.laurence@gmail.com	+3377788999
23	C022	NOMINUM	LAURENCE	LAURENCE	1	10	AVENUE FOCH	75003	PARIS	(null)	laurence.laurence@gmail.com	+3377788999
24	C023	NOMINUM	LAURENCE	LAURENCE	1	10	AVENUE FOCH	75003	PARIS	(null)	laurence.laurence@gmail.com	+3377788999
25	C110	NOMINUM	GENIE	ADAM	1	1	BOULVARD FOCH	93000	SPYHO-SUR-SEINE	FRANCE	adam.glemon@gmail.com	+3377788999
26	C119	NOMINUM	UNE	NP002	1	17	AVENUE D'ITALIE	75003	PARIS	FRANCE	marielesau@gmail.com	+33661750065
27	C120	NOMINUM	1	1	1	17	AVENUE D'ITALIE	75003	PARIS	FRANCE	marielesau@gmail.com	+33661750065
28	C121	NOMINUM	2 PAR 2	00000	1	07	AVENUE D'ITALIE	75003	PARIS	FRANCE	00000@gmail.com	+33661750065
29	C122	NOMINUM	DE PAR DE	00000	1	07	AVENUE D'ITALIE	75003	PARIS	FRANCE	00000@gmail.com	+33661750065
30	C123	NOMINUM	DE PAR DE	00000	1	07	AVENUE D'ITALIE	75003	PARIS	FRANCE	00000@gmail.com	+33661750065
31	C124	NOMINUM	DE PAR DE	00000	1	07	AVENUE D'ITALIE	75003	PARIS	FRANCE	00000@gmail.com	+33661750065
32	C125	NOMINUM	DE PAR DE	00000	1	07	AVENUE D'ITALIE	75003	PARIS	FRANCE	00000@gmail.com	+33661750065
33	C126	NOMINUM	DE PAR DE	00000	1	07	AVENUE D'ITALIE	75003	PARIS	FRANCE	00000@gmail.com	+33661750065
34	C127	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
35	C128	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
36	C129	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
37	C130	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
38	C131	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
39	C132	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
40	C133	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
41	C134	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
42	C135	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
43	C136	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
44	C137	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)
45	C138	NOMINUM	00000	1	(null)	(null)	(null)	(null)	(null)	(null)	(null)	(null)

Figure 4 – Création et affichage de la table VISU_ANOMALIES_CLIENTS

4.5 Détection des anomalies inférieures

Les contraintes sont ensuite appliquées colonne par colonne. Les contrôles portent notamment sur la civilité, le nom, le prénom, la catégorie, l'adresse, le code postal, la ville, le pays, le courriel, le téléphone, les dates, le groupe sanguin et les mots-clés.

Lorsqu'une valeur ne respecte pas une contrainte propre à sa colonne, elle peut être marquée avec le code :

<?!1ANOMALY>

All rows hidden: 23 in 3.107 seconds

| | COL1_CODEL1 | COL2_CODEL2 | COL3_CODEL3 | COL4_CODEL4 | COL5_CODEL5 | COL6_CODEL6 | COL7_CODEL7 | COL8_CODEL8 | COL9_CODEL9 | COL10_CODEL10 | COL11_CODEL11 | COL12_CODEL12 |
|----|-------------|-------------|-------------|---------------|---------------|--------------------------------------|--------------------------------------|--------------|-------------|---------------|---------------|---------------|
| 1 | C002 | LEDEUL | LEDEUL | NP002 | NP002 | marielesau@yahoo.fr | marielesau@yahoo.fr | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 2 | C004 | CLIMBERT | CLIMBERT | EVELINE | EVELINE | climbert.evelyn@gmail.com | climbert.evelyn@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 3 | C005 | PORT | PORT | ADAM | ADAM | adam.adam@gmail.com | adam.adam@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 4 | C006 | LE BON | LE BON | CLIMBERT | CLIMBERT | climbert.lebon@gmail.com | climbert.lebon@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 5 | C008 | VEVANT | VEVANT | JEAN-BAPTISTE | JEAN-BAPTISTE | jeanbaptiste@gmail.com | jeanbaptiste@gmail.com | 0007 | 0007 | +3377788999 | +3377788999 | +3377788999 |
| 6 | C009 | TRADON | TRADON | ADAM | ADAM | adam.adam@gmail.com | adam.adam@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 7 | C011 | PRENOM | PRENOM | 200/000 | 200/000 | jeanbaptiste@gmail.com | jeanbaptiste@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 8 | C013 | PORT | PORT | GABRIEL | GABRIEL | gabriel.fort@yahoo.fr | gabriel.fort@yahoo.fr | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 9 | C014 | ADAM | ADAM | ADAM | ADAM | adam.adam@gmail.com | adam.adam@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 10 | C015 | LAURENCE | LAURENCE | ADAM | ADAM | adam.adam@gmail.com | adam.adam@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 11 | C017 | KARYN | KARYN | KARYN | KARYN | karyn.ray@gmail.com | karyn.ray@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 12 | C018 | GENIE | GENIE | ADAM | ADAM | adam.glemon@gmail.com | adam.glemon@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 13 | C019 | GENIE | GENIE | ADAM | ADAM | adam.glemon@gmail.com | adam.glemon@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 14 | C110 | GENIE | GENIE | ADAM | ADAM | adam.glemon@gmail.com | adam.glemon@gmail.com | +3377788999 | 00070000 | +3377788999 | +3377788999 | +3377788999 |
| 15 | C119 | UNE | UNE | NP002 | NP002 | marielesau@yahoo.fr | marielesau@yahoo.fr | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 16 | C120 | 1 | 1 | NP002 | NP002 | marielesau@yahoo.fr | marielesau@yahoo.fr | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 17 | C121 | 2 PAR 2 | 2 PAR 2 | 00000 | 00000 | 00000@gmail.com | 00000@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 18 | C122 | DE PAR DE | DE PAR DE | 00000 | 00000 | 00000@gmail.com | 00000@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 19 | C123 | DE PAR DE | DE PAR DE | 00000 | 00000 | 00000@gmail.com | 00000@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 20 | C124 | DE PAR DE | DE PAR DE | 00000 | 00000 | 00000@gmail.com | 00000@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 21 | C125 | DE PAR DE | DE PAR DE | 00000 | 00000 | 00000@gmail.com | 00000@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 22 | C126 | DE PAR DE | DE PAR DE | 00000 | 00000 | 00000@gmail.com | 00000@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |
| 23 | C004 | ALIBABA | ALIBABA | Mystere | Mystere | secretaire.alibaba.mystere@gmail.com | secretaire.alibaba.mystere@gmail.com | +33661750065 | 00070000 | +33661750065 | +33661750065 | +33661750065 |

Figure 5 – Détection des anomalies intracolonne dans CLIENTS

4.6 Détection des doublons

Les colonnes devant contenir des valeurs uniques sont analysées afin d'identifier les répétitions. Le script contrôle notamment l'unicité du code client et de l'adresse électronique.

Le marqueur associé aux valeurs en double est :

<?D!ANOMALY>

All rows fetched: 6 in 0.060 seconds

| | VALEUR | NOMBRE |
|---|------------------------|--------|
| 1 | 2PAR2@GMAIL.COM | 6 |
| 2 | ADAM.GÉNIE@GMAIL.COM | 2 |
| 3 | GENIALEGENIE@GMAIL.COM | 2 |
| 4 | MARIEUNE@GMAIL.COM | 2 |
| 5 | USAPRESIDENT@LABAS.COM | 2 |

Figure 6 – Détection des valeurs en double

4.7 Détection des anomalies intérieures

Certaines anomalies ne peuvent être détectées qu'en comparant plusieurs colonnes. Le script vérifie par exemple la cohérence entre la civilité et la catégorie du client, ainsi que la cohérence chronologique entre la date de naissance et la date du premier contact.

Le marqueur utilisé pour ce type d'incohérence est :

<?!2ANOMALY>

All rows fetched: 26 in 0.100 seconds

| | COL01_CONTACT | COL02_CIVILITE | COL03_CATEG_1 | COL04_CATEG_2 | COL05_DATENAISSANCE_1 | COL06_DATENAISSANCE_2 | COL07_DATEPREMIERCONTACT_1 | COL08_DATEPREMIERCONTACT_2 |
|----|---------------|----------------|---------------------------|---------------|-----------------------|-------------------------|----------------------------|----------------------------|
| 1 | C001 | Madame | MADAME <?!2ANOMALY> | 1 | 17-JUN-91 | 1991-06-17 | 12-OCT-12 | 2012-12-12 |
| 2 | C002 | Madame | MADAME <?!2ANOMALY> | 1 | 05-JUL-91 | 1991-07-05 <?!2ANOMALY> | 05-JUL-90 | 1991-06-05 |
| 3 | C005 | Madame | MADAME <?!2ANOMALY> | 3 | 11-NOV-88 | 2000-11-11 | (null) | <?MISSINGVALUE> |
| 4 | C006 | Mademoiselle | MADAMOISELLE <?!2ANOMALY> | 1 | 16-OCT-90 | 1990-10-16 | 18-OCT-10 | 2010-10-18 |
| 5 | C007 | Mademoiselle | MADAMOISELLE <?!2ANOMALY> | 2 | 23-FEB-90 | 1990-02-23 | (null) | <?MISSINGVALUE> |
| 6 | C011 | Monsieur | MONSIEUR <?!2ANOMALY> | 2 | 01-JUN-88 | 2000-01-01 | 20-OCT-10 | 2020-10-10 |
| 7 | C012 | Monsieur | MONSIEUR <?!2ANOMALY> | 2 | 19-JUN-91 | 2001-06-19 | (null) | <?MISSINGVALUE> |
| 8 | C015 | Monsieur | MONSIEUR <?!2ANOMALY> | 7 | 7 <?!2ANOMALY> | (null) | <?MISSINGVALUE> | (null) |
| 9 | C016 | Madame | MADAME <?!2ANOMALY> | 7 | 7 <?!2ANOMALY> | (null) | <?MISSINGVALUE> | (null) |
| 10 | C017 | Madame | MADAME <?!2ANOMALY> | 1 | 01-JUN-90 | 1990-06-01 | 05-JAN-92 | 2002-01-05 |
| 11 | C019 | Madame | MADAME <?!2ANOMALY> | 3 | 17-SEP-88 | 1988-09-17 | 11-NOV-11 | 2011-11-11 |
| 12 | C020 | Madame | MADAME <?!2ANOMALY> | 3 | 17-SEP-88 | 1988-09-17 | 11-NOV-11 | 2011-11-11 |
| 13 | C021 | Madame | MADAME <?!2ANOMALY> | 3 | 17-SEP-88 | 1988-09-17 | 11-NOV-11 | 2011-11-11 |
| 14 | C022 | Mademoiselle | MADAMOISELLE <?!2ANOMALY> | 9 | 17-SEP-88 | 1988-09-17 | 11-NOV-11 | 2011-11-11 |
| 15 | C023 | Mademoiselle | MADAMOISELLE <?!2ANOMALY> | 9 | 17-SEP-88 | 1988-09-17 | 11-NOV-11 | 2011-11-11 |
| 16 | C118 | Madame | MADAME <?!2ANOMALY> | 3 | 17-SEP-88 | 1988-09-17 | (null) | <?MISSINGVALUE> |
| 17 | C119 | Madame | MADAME <?!2ANOMALY> | 6 | 01-JUN-91 | 1991-01-01 | (null) | <?MISSINGVALUE> |
| 18 | C120 | Madame | MADAME <?!2ANOMALY> | 1 | 01-JUN-91 | 1991-01-01 | (null) | <?MISSINGVALUE> |
| 19 | C120 | Madame | MADAME <?!2ANOMALY> | 1 | 17-SEP-88 | (null) | <?MISSINGVALUE> | (null) |
| 20 | C131 | Monsieur | MONSIEUR <?!2ANOMALY> | 9 | 17-SEP-78 | 1978-09-17 | (null) | <?MISSINGVALUE> |
| 21 | C295 | Monsieur | MONSIEUR <?!2ANOMALY> | 3 | 02-FEB-99 | 1999-02-02 | 20-JUN-91 | 1991-01-20 |
| 22 | C296 | Monsieur | MONSIEUR <?!2ANOMALY> | 3 | 19-NOV-95 | 1995-09-19 | 20-JUN-98 | 2000-01-20 |

Figure 7 – Détection des incohérences entre plusieurs colonnes

4.8 Traitement des valeurs manquantes

Les différentes représentations d'une donnée absente sont homogénéisées afin de pouvoir les identifier de manière uniforme.

Le code utilisé pour signaler une valeur manquante est :

<?MISSINGVALUE>

All rows fetched: 18 in 0.055 seconds

| | COL01_CODECLI | COL09_VELC1_2 | COL10_PAYSCL1 | COL10_PAYSCL1_2 | COL11_MAILCL1 | COL11_MAILCL1_2 | COL12_TELCL1 | COL12_TELCL1_2 |
|----|---------------|-----------------|-----------------|----------------------|-----------------------------------|-------------------------------------|----------------|----------------|
| 1 | C009 | PARIS | PARIS | <MISSINGVALUE> | alexandre.clemence@up13.fr | alexandre.clemence@up13.fr | +33149404071 | +33149404071 |
| 2 | C014 | ROME | ROME | ITALIE | adamo.adam@gmail.com | adamo.adam@gmail.com <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 3 | C015 | BAGDAD | BAGDAD | IRAQ | pala-labsent@saici | pala-labsent@saici <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 4 | C016 | CARTHAGE | CARTHAGE | IFRIQIA | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 5 | C021 | PARIS | PARIS | <MISSINGVALUE> | belie.laparisienne@gmail.com | belie.laparisienne@gmail.com | +33777889977 | +33777889977 |
| 6 | C022 | PARIS | PARIS | <MISSINGVALUE> | belie.africaine@hotmail.com | belie.africaine@hotmail.com | +33777889911 | +33777889911 |
| 7 | C023 | PARIS | PARIS | <MISSINGVALUE> | africaine@gmail.com | africaine@gmail.com | +33777889922 | +33777889922 |
| 8 | C127 | LONDON | LONDON | UNITED-KINGDOM | UNITED-KINGDOM <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) |
| 9 | C128 | LONDON | LONDON | UNITED-KINGDOM | UNITED-KINGDOM <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) |
| 10 | C129 | LONDON | LONDON | UNITED-KINGDOM | UNITED-KINGDOM <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) |
| 11 | C130 | NEW-YORK | NEW-YORK | UNITED-STATS-AMERICA | UNITED-STATS-AMERICA <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) |
| 12 | C131 | NEW-YORK | NEW-YORK | UNITED-STATS-AMERICA | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 13 | C295 | L'Hay-Les-Roses | L'Hay-Les-Roses | (null) | usapresident@labas.com | usapresident@labas.com <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 14 | C296 | (null) | <MISSINGVALUE> | (null) | (null) | - <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 15 | C297 | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> | - <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 16 | C298 | (null) | <MISSINGVALUE> | (null) | usapresident@labas.com | usapresident@labas.com <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 17 | C299 | (null) | <MISSINGVALUE> | (null) | - | - <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 18 | C300 | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> | - <?1ANDOMALY> | (null) | <MISSINGVALUE> |

Figure 8 – Détection et homogénéisation des valeurs manquantes

5 Visualisation, diagnostic et scoring

5.1 Visualisation des anomalies

Après la détection, le script permet d’afficher séparément les lignes contenant des anomalies et les lignes considérées comme correctes.

All rows fetched: 44 in 0.130 seconds

| | COL01_CODECLI | COL02_CVCL1_2 | COL03_NOMCL1_2 | COL04_PRENCL1_2 | COL05_CATCL1_2 | COL09_VELC1_2 | COL10_PAYSCL1_2 | COL11_MAILCL1_2 |
|----|---------------|--------------------------|----------------|-----------------|----------------|------------------|-----------------|--|
| 1 | C001 | Madame <?1ANDOMALY> | CLEMENT | EVE | 1 <?1ANDOMALY> | EPINAY-SUR-ORGE | FRANCE | eve.clement@gmail.com |
| 2 | C002 | Madame <?1ANDOMALY> | LESEUL | MERIE | 1 <?1ANDOMALY> | PARIS | FRANCE | marieleseu@yahoo.fr |
| 3 | C003 | Madame | UNIQUE | Znès | 2 | MARCHELLE | FRANCE | munique@gmail.com |
| 4 | C004 | Madame | CLEMENT | EVELYNE | 4 | EPINAY-SUR-SEINE | FRANCE | clement.evelyne@gmail.com <?1ANDOMALY> |
| 5 | C005 | Madam <?1ANDOMALY> | FORT | Bonne Marie | 3 <?1ANDOMALY> | ORLY-VILLE | FRANCE | jfort@hotmail.fr <?1ANDOMALY> |
| 6 | C006 | MADAMEISELE <?1ANDOMALY> | LE BON | CLÉRENCE | 1 <?1ANDOMALY> | EPINAY-SUR-SEINE | FRANCE | clement.le.bon@fo.fr <?1ANDOMALY> |
| 7 | C007 | MADAMEISELE <?1ANDOMALY> | TRAITOR | ALICE | 2 <?1ANDOMALY> | PARIS | FRANCE | alice.traiforg@yahoo.fr |
| 8 | C008 | Monsieur | VIVANT | JEROME-BAPTISTE | 3 | EPINAY-SUR-SEINE | FRANCE | jeanbaptiste <?1ANDOMALY> |
| 9 | C009 | Monsieur | CLEMENT | Alexandre | 1 | PARIS | <MISSINGVALUE> | alexandre.clemence@up13.fr |
| 10 | C010 | Monsieur | TRAITOR | Alexandre | 1 | PARIS | FRA | alexandre.traiforg@up13.fr |
| 11 | C011 | Monsieur <?1ANDOMALY> | PREMIER | DOS/EPH | 2 <?1ANDOMALY> | MARCHELLE | FRANCE | josephremier <?1ANDOMALY> |
| 12 | C012 | Monsieur <?1ANDOMALY> | CLEMENT | Adam | 2 <?1ANDOMALY> | VELLTAINEUSE | FRANCE | adam.clement@gmail.com |
| 13 | C013 | Monsieur | FORT | Gabriel | 5 | TUNISIE | TUNISIE | gabriel.fort@yahoo.fr |
| 14 | C014 | Monsieur | ADAM | ADAM | 5 | ROME | ITALIE | adamo.adam@gmail.com <?1ANDOMALY> |
| 15 | C015 | Monsieur <?1ANDOMALY> | Labsent | pala | 7 <?1ANDOMALY> | BAGDAD | IRAQ | pala-labsent@saici <?1ANDOMALY> |
| 16 | C016 | Madame <?1ANDOMALY> | obsolete | Kadye | 7 <?1ANDOMALY> | CARTHAGE | IFRIQIA | <MISSINGVALUE> |
| 17 | C017 | Madame <?1ANDOMALY> | RAYKH | Karym | 1 <?1ANDOMALY> | CARTHAGE | TUNISIE | karym.raym@gmail.com |
| 18 | C018 | Madame | GENE | ADAM | 6 | EPINAY SUR SEINE | FRANCE | adam.gene@gmail.com <?1ANDOMALY> |
| 19 | C019 | Madame <?1ANDOMALY> | GENE | GENE | 3 <?1ANDOMALY> | PARIS | FRANCE | genalegene@gmail.com <?1ANDOMALY> |
| 20 | C020 | Madame <?1ANDOMALY> | GENE | GENE | 3 <?1ANDOMALY> | PARIS | FRANCE | genalegene@gmail.com <?1ANDOMALY> |
| 21 | C021 | Madame <?1ANDOMALY> | LAPARISIENNE | Belle | 3 <?1ANDOMALY> | PARIS | <MISSINGVALUE> | belie.laparisienne@gmail.com |

Figure 9 – Visualisation des lignes contenant des anomalies

5.2 Traitement des valeurs manquantes

Les valeurs identifiées comme manquantes sont ensuite converties en véritables valeurs NULL dans les colonnes de travail afin d’homogénéiser la représentation des absences de données.

All rows fetched: 18 in 0.029 seconds

| | COL01_CODECLI | COL10_PAYSCL1 | COL10_PAYSCL1_2 | COL11_MAILCL1 | COL11_MAILCL1_2 | COL12_TELCL1 | COL12_TELCL1_2 |
|----|---------------|----------------------|-----------------------------|------------------------------|-------------------------------------|--------------|----------------|
| 1 | C009 | (null) | <MISSINGVALUE> | alexandre.clemence@up13.fr | alexandre.clemence@up13.fr | +33149404071 | +33149404071 |
| 2 | C014 | ITALIE | ITALIE | adamo.adam@gmail.com | adamo.adam@gmail.com <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 3 | C015 | IRAQ | IRAQ | pala-labsent@saici | pala-labsent@saici <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 4 | C016 | IFRIQIA | IFRIQIA | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 5 | C021 | (null) | <MISSINGVALUE> | belie.laparisienne@gmail.com | belie.laparisienne@gmail.com | +33777889977 | +33777889977 |
| 6 | C022 | (null) | <MISSINGVALUE> | belie.africaine@hotmail.com | belie.africaine@hotmail.com | +33777889911 | +33777889911 |
| 7 | C023 | (null) | <MISSINGVALUE> | africaine@gmail.com | africaine@gmail.com | +33777889922 | +33777889922 |
| 8 | C127 | UNITED-KINGDOM | UNITED-KINGDOM <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 9 | C128 | UNITED-KINGDOM | UNITED-KINGDOM <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 10 | C129 | UNITED-KINGDOM | UNITED-KINGDOM <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 11 | C130 | UNITED-KINGDOM | UNITED-KINGDOM <?1ANDOMALY> | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 12 | C131 | UNITED-STATS-AMERICA | UNITED-STATS-AMERICA | (null) | <MISSINGVALUE> | (null) | <MISSINGVALUE> |
| 13 | C295 | UNITED-STATS-AMERICA | UNITED-STATS-AMERICA | usapresident@labas.com | usapresident@labas.com <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 14 | C296 | (null) | <MISSINGVALUE> | (null) | - <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 15 | C297 | (null) | <MISSINGVALUE> | (null) | - <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 16 | C298 | (null) | <MISSINGVALUE> | usapresident@labas.com | usapresident@labas.com <?1ANDOMALY> | (null) | <MISSINGVALUE> |
| 17 | C299 | (null) | <MISSINGVALUE> | - | - <?1ANDOMALY> | (null) | <MISSINGVALUE> |

Figure 10 – Correction et homogénéisation des valeurs manquantes

5.3 Correction des valeurs aberrantes

Le script utilise également des mesures de similarité afin d'identifier des valeurs très proches pouvant correspondre à des fautes de saisie, par exemple des variantes de noms de villes ou de pays.

All rows fetched: 3 in 0.102 seconds

| | COL1 | NBR1 | COL1BIS | NBR2 |
|---|------------------|------|------------------|------|
| 1 | PARIS | 4 | paris | 1 |
| 2 | EPINAY SUR SEINE | 1 | EPINAY-SUR-SEINE | 3 |
| 3 | MARCHEILLE | 1 | MARCHEILLLE | 1 |

Figure 11 – Détection et correction de valeurs similaires

5.4 Détecteurs fonctionnels

Le script étudie également certaines relations entre colonnes, par exemple la dépendance entre la ville et le pays, afin d'identifier des incohérences qui ne sont pas visibles lorsqu'une colonne est contrôlée isolément.

All rows fetched: 23 in 0.045 seconds

| | COL09_VILCLI | COL10_PAYSCLI | NOMBRE |
|----|------------------|----------------------|--------|
| 1 | EPINAY SUR SEINE | FRANCE | 1 |
| 2 | PARIS | FRANCE | 1 |
| 3 | PARIS | FRANCE | 2 |
| 4 | PARIS | france | 1 |
| 5 | paris | france | 1 |
| 6 | BAGDAD | IRAQ | 1 |
| 7 | CARTHAGE | IFRIQIA | 1 |
| 8 | CARTHAGE | TUNISIE | 1 |
| 9 | EPINAY SUR SEINE | FRANCE | 1 |
| 10 | EPINAY-SUR-ORGE | FRANCE | 1 |
| 11 | EPINAY-SUR-SEINE | FRANCE | 3 |
| 12 | LONDON | United-KINGDOM | 2 |
| 13 | LONDON | United-Kingdom | 1 |
| 14 | MARCHEILLE | FRANCE | 1 |
| 15 | MARCHEILLLE | FRANCE | 1 |
| 16 | NEW-YORK | UNITED-STATS-AMERICA | 1 |
| 17 | ORLY-VILLE | FRANCE | 1 |
| 18 | Oxford | United KINGDOM | 1 |
| 19 | PARIS | FRANCE | 1 |
| 20 | PARIS | FRANCE | 8 |
| 21 | ROME | ITALIE | 1 |
| 22 | TUNIS | TUNISIE | 1 |
| 23 | VILLETANEUSE | FRANCE | 1 |

Figure 12 – Analyse des dépendances fonctionnelles entre colonnes

5.5 Résultat après nettoyage

Après les opérations de correction, les données sont de nouveau affichées afin de vérifier l'amélioration de leur qualité.

All rows fetched: 44 in 0.112 seconds

| | COL01_CODCLI | COL02_CIVCLI | COL03_NOMCLI | COL04_PRENCLI | COL09_VILCLI | COL10_PAYSCLI | COL11_MAILCLI | COL12_TELCLI | COL18_GSCLI |
|----|--------------|--------------|--------------|---------------|------------------|---------------|----------------------------|---------------|-------------|
| 1 | C001 | Madame | CLEMENT | EVE | EPINAY-SUR-ORGE | FRANCE | eve.clement@gmail.com | +33777889911 | A+ |
| 2 | C002 | Madame | LESEUL | MARIE | PARIS | FRANCE | marieleseul@yahoo.fr | +330617586565 | A+ |
| 3 | C003 | Madame | UNIQUE | Inès | MARCHELILLE | FRANCE | munique@gmail.com | +33717889922 | B+ |
| 4 | C004 | Madame | CLEMENCE | EVELYNE | EPINAY-SUR-SEINE | FRANCE | clemence.evelyne@gmail.com | +33777889933 | B+ |
| 5 | C005 | Madam | FORT | anne marie | ORLY-VILLE | FRANCE | jfort@hotmail.fr | +33777889944 | A- |
| 6 | C006 | Mademoiselle | LE BON | Clémence | EPINAY-SUR-SEINE | FRANCE | clemence.lebon@cfo.fr | +33777889955 | A+ |
| 7 | C007 | Mademoiselle | TRAIFOR | Alice | PARIS | FRANCE | alice.traifor@yahoo.fr | +33777889966 | A+ |
| 8 | C008 | Monsieur | VIVANT | JEAN-BAPTISTE | EPINAY-SUR-SEINE | FRANCE | jeanbaptiste@ | 0607 | A+ |
| 9 | C009 | Monsieur | CLEMENCE | Alexandre | PARIS | (null) | alexandre.clemence@up13.fr | +33149404071 | |
| 10 | C010 | Monsieur | TRAIFOR | Alexandre | PARIS | FRANCE | alexandre.traifor@up13.fr | 06070600 | B+ |
| 11 | C011 | Monsieur | PREMIER | JOS//EPH | MARCHELILLE | FRANCE | Joseff@premier | +33777889977 | B+ |
| 12 | C012 | Monsieur | CLEMENT | Adam | VILLETANEUSE | FRANCE | adam.clement@gmail.com | +33149404072 | B+ |
| 13 | C013 | Monsieur | FORT | Gabriel | TUNIS | TUNISIE | gabriel.fort@yahoo.fr | +21624001777 | A+ |
| 14 | C014 | Monsieur | ADAM | ADAMO | ROME | ITALIE | adamo.adam@gmail.com | (null) | AB+ |
| 15 | C015 | Monsieur | Labent | pala | BAGDAD | IRAQ | pala-labent@uic1 | (null) | A+ |
| 16 | C016 | Madame | obsolete | kadyw | CARTHAGE | IFRIQIA | (null) | (null) | A+ |
| 17 | C017 | Madame | RAHYM | Karym | CARTHAGE | TUNISIE | karym.rahy@gmail.com | +21624008444 | AB+ |

Figure 13 – Résultat obtenu après nettoyage et standardisation

5.6 Calcul du score QUALI-SCORE

Le score de qualité global est calculé directement en SQL à partir de la table de travail VISU_ANOMALIES_CLIENTS. Il repose sur la formule officielle du barème QUALI-SCORE :

$$S = \frac{N \times M - a}{N \times M} \times 100 \quad (1)$$

où :

- N : nombre de tuples (lignes de la table CLIENTS) ;
- M : nombre de colonnes analysées ($M = 19$) ;
- a : nombre total d'anomalies détectées.

Requête SQL utilisée

```
SQL> SELECT
COUNT(*) * 19 AS TOTAL_CELLULES,
SUM(SCORE_TOTALANOMALIES) AS TOTAL_ANOMALIES,
ROUND(
100 * (COUNT(*) * 19 - SUM(SCORE_TOTALANOMALIES))
/ (COUNT(*) * 19),
2
) AS QUALI_SCORE
FROM VISU_ANOMALIES_CLIENTS;
```

| | | | | | | | |
|----------------|-----------------|-------------|---|---|---|---|---|
| 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 |
| TOTAL_CELLULES | TOTAL_ANOMALIES | QUALI_SCORE | | | | | |
| ----- | ----- | ----- | | | | | |
| 855 | 372 | 56.49 | | | | | |

```
SQL> █
```

Figure 14 – Requête SQL de calcul du score QUALI-SCORE et résultat obtenu

Résultats obtenus

| Indicateur | Valeur |
|-----------------|---------------|
| TOTAL_CELLULES | 855 |
| TOTAL_ANOMALIES | 372 |
| QUALI_SCORE | 56.49% |

Table 1 – Résultats du calcul QUALI-SCORE

Interprétation

Avec un score de **56.49%**, la base de données CLIENTS se situe au **niveau C (jaune)** du barème QUALI-SCORE :

$$S = \frac{855 - 372}{855} \times 100 = \frac{483}{855} \times 100 = 56.49\%$$

Ce score traduit une qualité **moyenne** : près de la moitié des cellules contient au moins une anomalie (format, valeur manquante, doublon ou incohérence intercolonnes). Des opérations de nettoyage approfondies sont donc nécessaires pour atteindre un niveau A ou B.

Barème QUALI-SCORE

| Niveau | A | B | C | D | E |
|---------|---------|------------|--------|--------|-------|
| Couleur | Vert | Vert clair | Jaune | Orange | Rouge |
| Score | 80–100% | 60–80% | 40–60% | 20–40% | 0–20% |

Table 2 – Barème d'évaluation QUALI-SCORE

Évaluation graphique




Figure 15 – Évaluation graphique : 56.49% correctes contre 43.51% erronées

6 Résultats obtenus

Cette section présente les résultats réellement obtenus lors de l'exécution des scripts. Les captures précédentes permettent de montrer les anomalies observées, les scores calculés et l'effet des opérations de nettoyage.

| Indicateur | Valeur obtenue |
|---------------------------------|------------------|
| Nombre de lignes CLIENTS | 45 |
| Nombre de colonnes analysées | 19 |
| Nombre total de cellules | 855 |
| Nombre de valeurs manquantes | 231 |
| Nombre de 1ANOMALY | 92 |
| Nombre de 2ANOMALY | 53 |
| Nombre de 3ANOMALY | 0 |
| Nombre de DANOMALY | 10 |
| Nombre total d'anomalies | 372 |
| Score QUALLI-SCORE | 56.49% |
| Niveau QUALLI-SCORE | C (jaune) |

Table 3 – Résumé des résultats obtenus et score QUALLI-SCORE

6.1 Checklist Data Base

Conformément au sujet, les six axes de la checklist ont été traités :

| Axe | Traité | Section du rapport |
|-------------------------|--------|---------------------|
| Normal Forms | ✓ | Sections 4.1 – 4.4 |
| Missing Values | ✓ | Sections 4.8 et 5.2 |
| Heterogeneity | ✓ | Section 5.3 |
| Functional Dependencies | ✓ | Section 5.4 |
| Analytics Metrics | ✓ | Sections 5.6 et 6 |
| Duplicates | ✓ | Section 4.6 |

Table 4 – Checklist Data Base appliquée au projet

7 Limites et observations

La qualité du diagnostic dépend directement des contraintes définies et des expressions régulières utilisées. Certaines règles peuvent être trop restrictives ou ne pas couvrir tous les cas possibles.

De plus, les corrections fondées sur la similarité ou sur des règles sémantiques doivent être vérifiées avant validation, car deux valeurs proches ne représentent pas nécessairement la même information.

8 Conclusion

Ce TP a permis de mettre en oeuvre une démarche progressive de qualité des données sur la base GesCOM–GesFAC.

Le script MFB04 a fourni des requêtes SQL avancées permettant d’interroger les données et de mettre en évidence certaines anomalies syntaxiques ou sémantiques.

Le script MFB05 a présenté l’import de données externes avec SQL*Loader et a introduit un premier mécanisme de diagnostic distinguant les valeurs valides, invalides et manquantes.

Enfin, le script MFB06 a structuré l’ensemble du processus de qualité : création d’une copie de travail, détection des anomalies intracolonne et intercolonnes, détection des doublons, homogénéisation des valeurs manquantes, visualisation, profilage global, calcul du score **QUALLI-SCORE** et nettoyage des données.

Le score final obtenu est de **56.49%**, ce qui correspond au **niveau C (jaune)** du barème QUALLI-SCORE. Ce résultat témoigne d’une qualité moyenne nécessitant encore des opérations de nettoyage. L’utilisation d’une table de travail permet de conserver la source initiale tout en rendant les anomalies visibles et mesurables. Le nettoyage peut ensuite combiner normalisation syntaxique, règles sémantiques, fonctions de similarité et dépendances entre colonnes.